

우수학부생 연구학점제 연구결과보고서(학생용)

○ 연구제목: Post-training quantization 방식 기반의 가변 정밀도를 갖는 심층신경망 양자화 기법

○ 연구기간: 2024.09.01 - 2024-12-20

○ 연구결과 요약

0. 연구 목적

기존의 flexible quantization 기법들은 학습 과정에서 과도한 비용을 요구하며, 이는 PTQ보다 더 많은 학습 데이터와 자원을 필요로 하는 quantization aware training(QAT)에서 특히 두드러집니다. 본 연구는 이러한 비용 문제를 해결하며 온디바이스 AI를 위한 효율적인 컴퓨터 비전 모델을 설계하고자 합니다. 이를 위해 PTQ를 컴퓨터 비전 모델에 적용하여, 추론 시 유연한 비트 폭(flexible bit-width)을 제공하는 기법들을 연구·개발하려고 합니다.

현재 다수의 컴퓨터 비전 모델이 오픈소스로 공개되고 있지만, 모델 학습에 사용된 데이터셋은 점점 더 공개되지 않고 있으며, 거대한 pretrained 모델을 fine-tuning하는 데 드는 비용 역시 매우 큽니다. 이러한 점에서 fine-tuning이 필요한 QAT보다 fine-tuning이 필요 없는 PTQ가 현실적인 상용화 방식이라고 가정하고 연구를 진행하고자 합니다.

PTQ 적용 후 모델의 성능 저하가 심하다면 양자화의 실효성이 낮아질 수 있습니다. 따라서 본 연구에서는 ResNet, EfficientNet과 같은 대표적인 CNN(convolutional neural network) 모델 및 ViT(vision transformer)에 연구 기법을 적용하고, ImageNet과 같은 대표적인 이미지 분류 데이터셋에서 최신 기법들과 성능을 비교할 것입니다. 이를 통해 개발한 기법의 우수성과 실용성을 검증할 계획입니다.

1. 초록

PTMQ (Post-Training Multi-bit Quantization)는 임의의 비트폭(bit-width)에서 실시간으로 동작 가능한 activation 양자화를 가능하게 하는 프레임워크이며, 올해 AAAI 국제 컨퍼런스에서 출시된 연구성과물입니다. 이 기술은 계산 요구를 크게 줄이면서 블록 단위 복원, Multi-bit Feature Mixer(MFM), Group-wise Distillation Loss(GD-Loss)를 통해서 컴퓨터비전 모델의 좋은 성능을 냅니다. 기존의 양자화 방법에 비해 최대 100배의 속도 개선을 이루며, 추가적인 학습 자원 없이 균일 및 혼합 정밀도(mixed-precision) 양자화를 지원합니다. PTMQ는 경량화된 모델 배치를 위해 최적화된 솔루션을 제공하며, 다양한 실제 환경에서 탁월한 활용 가능성을 입증하고 있습니다. 더 나아가, 이러한 접근법은 모델 경량화와 정확도 간의 균형을 재정립하며, 높은 유연성을 요구하는 응용 시나리오에서 효과적으로 적용될 수 있습니다.

이번 URP를 통해서 저희는:

- (1) post-training quantization에 대한 학습
 - (2) multi-bit 양자화에 대한 공부를 소스코드 없는 논문을 구현 후 오픈소스로 공개
 - (3) PTMQ 방식을 개선하는 방향으로 연구
- 위주로 성과를 냈습니다.

2. PTMQ 논문 직접 구현

저희 팀은 PTMQ 논문의 소스 코드가 공개되지 않은 상황에서도, 논문에서 제시된 이론적 내용과 다른 유사한 오픈소스 코드를 학습한 것을 기반으로 PTMQ를 직접 구현하여 성능 재현하면서 저희 코드를 검증했습니다. 특히 PTMQ의 주요 기법들은 효율적인 양자화를 통해 다양한 비트 폭에서의 유연성을 확보하고, 모델의 정확도를 유지하는 것을 목표로 하고 있습니다. 이를 구현하기 위해 PyTorch를 활용하여 알고리즘의 각 요소를 체계적으로 구성하였으며, 다양한 실험을 통해 성능을 검증하였습니다.

우선, 블록 단위 재구성 (block reconstruction) 방식을 적용하여 모델을 여러 블록으로 나누고, 각 블록에 대해 양자화 오류를 최소화할 수 있도록 최적화 과정을 설계했습니다. 이 과정은 PTQ(Post-Training Quantization) 방법론을 기반으로 하며, 각 블록의 매개변수를 독립적으로 최적화하여 전체 모델의 성능을 유지하는 데 중점을 두었습니다. 이를 통해 PTMQ는 다양한 비트 폭에서 실시간으로 전환할 수 있는 특성을 구현할 수 있었습니다.

다음으로, 다중 비트 특징 혼합(Multi-bit Feature Mixer, MFM) 기법을 구현했습니다. MFM은 다양한 비트 폭에서 생성된 특징들을 효과적으로 결합하여 모델의 견고성을 강화하는 역할을 합니다. 이를 위해, 각 블록에서 다양한 비트 폭의 출력 특징을 혼합하여 다음 블록의 입력으로 사용하는 방식을 설계했습니다. 이를 통해 모델은 특정 비트 폭에 치우치지 않고 모든 비트 폭에서 안정적으로 작동할 수 있도록 했습니다.


마지막으로, 그룹별 지식 증류 손실(Group-Distill Loss, GD-Loss)을 활용하여 다양한 비트 폭 그룹 간의 상관성을 강화했습니다. GD-Loss는 고비트 폭 그룹에서 얻어진 특징이 저비트 폭 그룹의 양자화 과정을 지원하도록 설계되어, 저비트 폭에서도 성능 저하를 최소화하는 데 기여합니다. 이 과정은 모델의 전반적인 정확도와 견고성을 향상시키며, 특히 저비트 폭 환경에서 큰 효과를 발휘했습니다.

3. 결과 및 성과

3.1. PTMQ 구현 결과

Model	W3A3	W4A4	W6A6	W8A8	FP32
ResNet-18	63.6	68.67	70.67	70.96	71
ResNet-50	69.21	74.4	76.39	76.46	76.62
RegNetX-600 MF	61.57	70.47	73.43	73.67	73.83
MobileNet-V2	50.65	67.81	72.09	72.51	72.4
ViT-B/224/16	76.93	77.56	77.51	78.60	79.15

위 결과는 저희가 구현한 코드에서 나온 모델의 성능입니다. 이를 논문에서 제시한 수치들과 비교한 것이 다음과 같습니다:



위 그래프 및 테이블의 결과들이 조금씩 달랐습니다. 10개 이상의 hyperparameter들이 논문에 공개되지 않고, 이러한 값들이 논문 저자들의 값들과 미세하게 다를 수 있기 때문이라고 추정합니다. 하지만 정확한 결과의 일치보다, PTMQ라는 연구성과물을 오픈소스 코드없이 구현 후 오픈소스 코드로 전환한 것에 큰 의의를 두고 있습니다. 코드는 <https://github.com/d7chong/ptmq-pytorch>에서 확인하실 수 있습니다.

3.2. PTMQ_W (Post-Training Multi-bit Quantization for Weights)

3.2.1. 배경

Real-Time application과 제한된 환경에 대해서 모델의 크기를 줄이고 성능 저하를 최소화하기 위하여 딥러닝 모델에 양자화를 적용할 수 있습니다. Activation을 multi-bit으로 quantize하는 PTMQ 기법을 확장하여, Weight 역시 multi-bit으로 quantize하는 방법을 제안합니다.

3.2.2. PTMQ-W 구현

PTMQ는 activation을 multi-bit으로 quantize하는 방법론으로써, 서로 다른 bit-width의 activation 간 상호보완을 통하여 성능을 향상시키는 특징을 가지고 있습니다. 높은 정밀도를 가진 그룹의 정보가 낮은 정밀도를 가진 그룹의 손실된 정보를 보완하는 방식으로 작동하며, 전체적인 모델의 성능을 향상시킬 수 있습니다.

앞서 구현하였던 PTMQ의 코드를 확장하여서, activation의 quantizer는 1개로 고정을 하고, weight의 layer를 3개로 복제하여 각각 low-bit, middle-bit, high-bit로 나누어서 레이어 별로 quantizer를 생성하였습니다. 해당 구조는 PTMQ와 마찬가지로 Weight의 다양한 bit-width 설정을 통하여 모델의 성능 향상이 예상되었습니다.

Weight quantizer를 low bit, middle bit, high bit로 분류하여 다양한 bit-configuration을 통하여 PTMQ와의 성능을 비교하였습니다.


3.2.3. 다양한 CNN 모델에서의 적용 및 검증

실험 환경

- Iterations of Reconstruction : 5000
- Bit-configurations
- W4A4 : weight 4,6,8 bit / activation 4 bit
- W6A6 : weight 4,6,8 bit / activation 6 bit
- W8A8 : weight 4,6,8bit / activation 8 bit

	W3A3	W4A4	W6A6	W8A8
ResNet-18	62.86	67.16	68.49	68.95
ResNet-50	69.45	73.69	75.49	75.59
MobileNet-v2	—	63.31	71.91	72.56
RegNetX	—	54.04	72.29	73.22

PTMQ_W Bit-Width Performance on ImageNet (Top-1 Accuracy)



3.2.4. 결론

해당 연구에서는 PTMQ의 activation quantize 방식을 확장하여, weight 역시 multi-bit으로 quantize 하는 새로운 방법론을 제시하였습니다. 이를 통하여 다양한 bit-configuration과 CNN 모델에서의 성능을 검증한 결과, PTMQ-W가 PTMQ와 유사한 성능을 유지하면서도 BRECQ, Qdrop 등의 기존 방법론보다 우수한 성능을 보임을 확인하였습니다. 이러한 결과로 multi-bit weight quantization이 딥러닝 모델의 양자화에 적합한 방법임을 알 수 있습니다.

4. 향후 과제

지금까지 소스코드가 없던 PTMQ를 직접 구현, 그리고 PTMQ에서 제시한 multi-bit activation PTQ 대신 multi-bit weight PTQ 방식인 PTMQ_W를 구현하고 실험하는 것들에 집중했습니다. 하지만 저희는 이어서 multi-bit weight 및 multi-bit activation 양자화하는 framework인 PTMQ+를 연구개발하고 있으며, 방학동안 이어서 연구를 진행하려고 합니다.

2024 년 12 월 20 일

제출자 : 정지연 

일반대학원장 귀하